Prédiction de fin d'orage

Rapport d'Analyse Exploratoire des Données

Réponse à l'appel d'offre **Météorage**

Analyse de la dynamique spatio-temporelle des éclairs
autour de 5 aéroports européens

Mars 2026

Données : segment_alerts_all_airports_train.csv
507 071 éclairs · 5 aéroports · 769 sessions d'alerte

Table des matières

1 Introduction et contexte **2**
1.1 Description du jeu de données 2

2 Répartition par aéroport **3**

3 Analyse temporelle **3**
3.1 Distribution mensuelle et horaire 3
3.2 Heatmap mois × heure 4
3.3 Activité par aéroport et par mois 4

4 Caractéristiques physiques des éclairs **5**
4.1 Définition de Maxis et Ratio IC 5
4.2 Rose des azimuts 6

5 Analyse géographique **6**

6 Analyse des sessions d'alerte **7**
6.1 Durée et intensité des sessions 7
6.2 Spécificités par aéroport 7

7 Analyse de la variable cible **8**
7.1 Formulation du problème de modélisation 8
7.2 Exemple de session d'alerte 9

8 Corrélations et structure des données **9**

9 Conclusions et orientations pour la modélisation **10**
9.1 Features candidates pour la modélisation 10

A Environnement technique **10**

1 Introduction et contexte

Le problème posé par Météorage est celui de l'**estimation probabiliste de la fin d'un orage**. Aujourd'hui, les alertes restent actives une durée fixe (30 à 60 minutes) après le dernier éclair cloud-to-ground (*CG*) dans la zone de surveillance. Pour des secteurs critiques comme les aéroports, cette approche conservatrice engendre des pertes d'exploitation significatives.

L'objectif est de développer un modèle capable d'exploiter la **dynamique spatio-temporelle** des éclairs pour estimer, en temps réel, la probabilité que l'orage soit terminé.

1.1 Description du jeu de données

Variable	Description	Type
`lightning_id`	Identifiant unique global de l'éclair	int
`lightning_airport_id`	Identifiant éclair dans le contexte aéroport	int
`date`	Timestamp UTC de l'éclair	datetime
`lon, lat`	Coordonnées géographiques de l'éclair	float
`amplitude`	Courant de foudre en kA (signe = polarité)	float
`maxis`	Amplitude normalisée / indicateur d'intensité	float
`icloud`	`True` = intra-cloud, `False` = cloud-to-ground	bool
`dist`	Distance à l'aéroport (km, rayon max 50 km)	float
`azimuth`	Angle par rapport au Nord (°)	float
`airport`	Nom de l'aéroport (5 valeurs)	str
`airport_alert_id`	Identifiant de la session d'alerte (NaN si hors alerte)	float
`is_last_lightning_cloud_ground`	**Cible** : dernier éclair CG de la session ?	bool/NaN

Table 1 – Description des variables du jeu de données

Statistiques globales

- **507 071** éclairs au total
- **5 aéroports** : Ajaccio, Bastia, Biarritz, Nantes, Pise
- **769 sessions d'alerte** distinctes (`airport_alert_id` non nul)
- **56 599 éclairs en alerte** ($\approx$ 11% du total)
- La variable cible est disponible uniquement pour les éclairs CG en session d'alerte
- Période couverte : 2016 (au moins) avec pics estivaux marqués

2 Répartition par aéroport

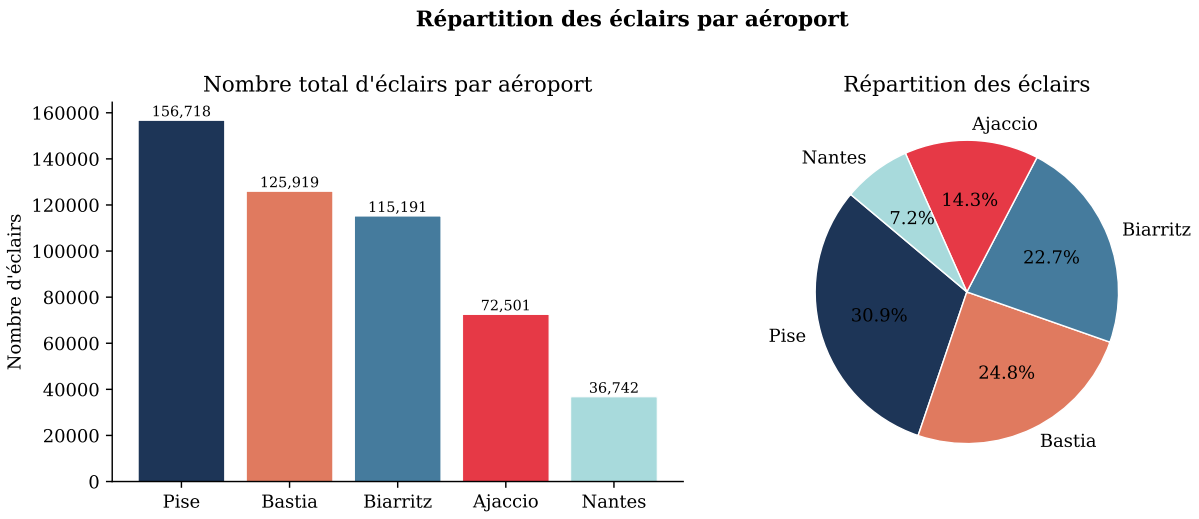

Figure 1 – Distribution des éclairs entre les 5 aéroports. Pise concentre la majorité de l'activité orageuse.

Les 5 aéroports présentent des niveaux d'activité orageuse très différents. Pise (Toscane, Italie) domine avec plus de 30% des éclairs totaux, en raison de sa position géographique favorable au développement convectif (convergence mer Ligure / relief apennin). Bastia et Biarritz suivent avec des niveaux d'activité similaires, puis Ajaccio, et enfin Nantes, qui connaît l'activité la plus faible. On remarque que Bastia et Ajaccio, les deux aéroports corses, ont des niveaux d'activité orageuse différentes (presque 2 fois plus d'éclairs à Bastia qu'à Ajaccio), bien qu'on verra plus tard que le profil temporel est très similaire.

3 Analyse temporelle

3.1 Distribution mensuelle et horaire

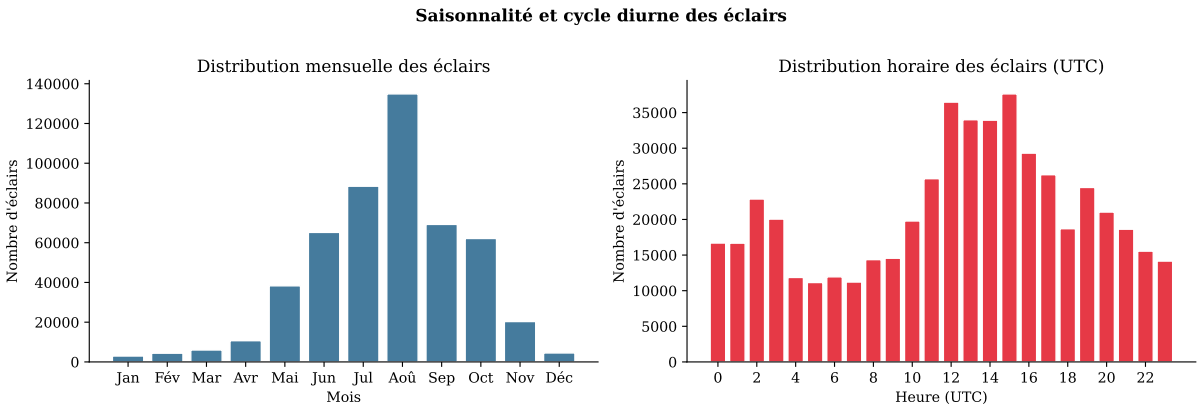

Figure 2 – Distribution temporelle des éclairs : saisonnalité marquée avec un pic en été (juin-septembre) et un cycle diurne prononcé avec maximum en fin d'après-midi.

Deux patterns temporels fondamentaux se dégagent :

— **Saisonnalité estivale** : la convection thermique atteint son maximum en été, avec un pic en juillet-août. La période novembre-mars est quasi inerte.

— **Cycle diurne convectif** : le maximum d'éclairs se situe dans l'après-midi, entre 12h et 14h30 UTC, correspondant au pic de la couche limite convective après son réchauffement.

3.2 Heatmap mois × heure

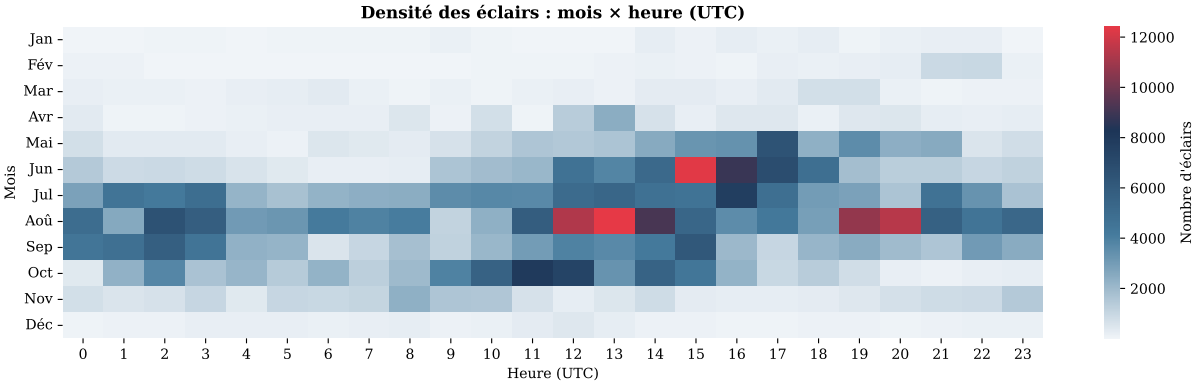

Figure 3 – Densité combinée mois * heure. Le quadrant "été / après-midi" concentre l'essentiel de l'activité. Les orages nocturnes (00h-06h UTC) sont plus fréquents en juillet-août, associés aux systèmes convectifs méso-échelle.

3.3 Activité par aéroport et par mois

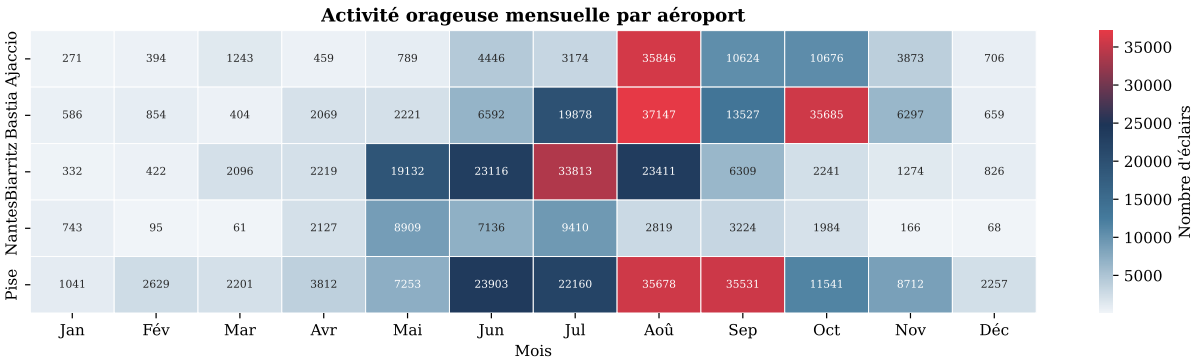

Figure 4 – Répartition mensuelle de l'activité orageuse par aéroport. On observe que Biarritz présente un pic précoce et très étalé s'amorçant dès mai-juin jusqu'en août. Nantes a également une activité concentrée sur le début d'été (mai–juillet). Pise connaît un pic tardif en août–septembre, tandis qu'Ajaccio et Bastia, avec des profils quasi-identiques, voient l'essentiel de leur activité orageuse repoussé de août à octobre, période de fort flux de chaleur de la mer Méditerranée.

4 Caractéristiques physiques des éclairs

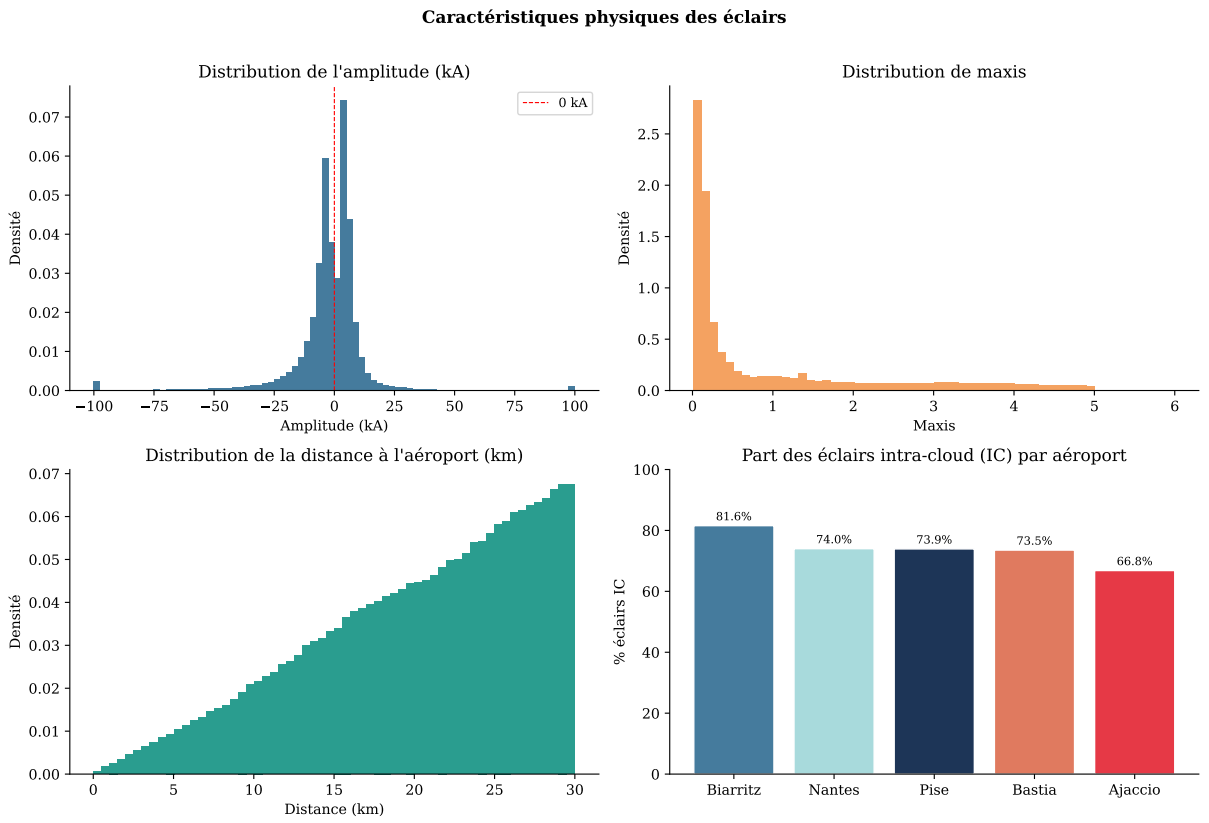

Figure 5 – Distributions des variables physiques. **Amplitude** : distribution bimodale asymétrique, la majorité des éclairs CG sont négatifs. **Maxis** : variable interne concentrée entre 0 et 2 avec une queue lourde. **Distance** : distribution croissante linéairement — ce phénomène est un artefact géométrique attendu car la surface de l'anneau de distance r est proportionnelle à $2\pi r$. Pour une densité spatiale d'éclairs parfaitement homogène, le nombre d'éclairs augmente linéairement avec la distance. **Ratio IC** : varie de 66% (Ajaccio) à plus de 80% (Biarritz).

4.1 Définition de Maxis et Ratio IC

Maxis est un indicateur de gradient d'intensité couramment utilisé par Météorage. Il s'agit d'une valeur normalisée (souvent corrélée à l'amplitude maximale ou à la raideur du front de courant de l'éclair) qui aide à distinguer différents types ou puissances de décharges.

Le rapport éclairs intra-cloud (**IC**) sur le total d'éclairs est un indicateur du stade de développement d'un orage. Un ratio élevé en début de session indique un orage en phase de maturation ; un ratio croissant en fin de session peut signaler la dissipation.

4.2 Rose des azimuts

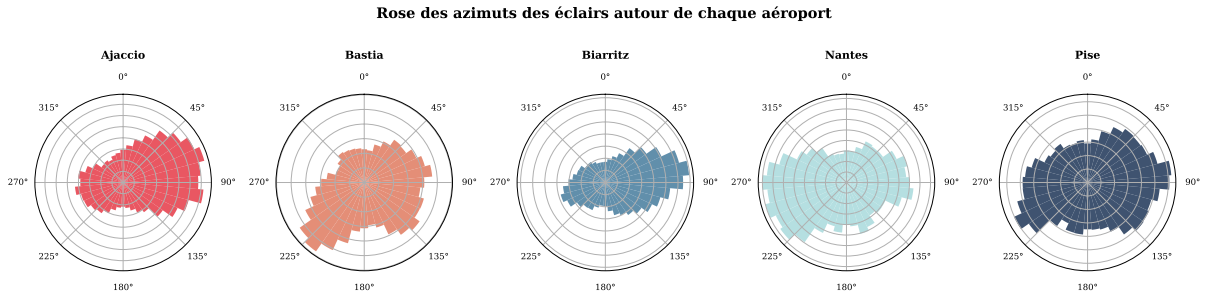

Figure 6 – Distribution angulaire (azimut) des éclairs. Nantes affiche un fort flux en provenance du sud-ouest. Biarritz se distingue par un flux d'est dominant (descente des Pyrénées). Pour la Corse, Bastia présente des apports sud-ouest et sud-est, tandis qu'Ajaccio est majoritairement à l'est. Pise connaît une répartition plus symétrique avec deux axes dominants est/ouest.

5 Analyse géographique

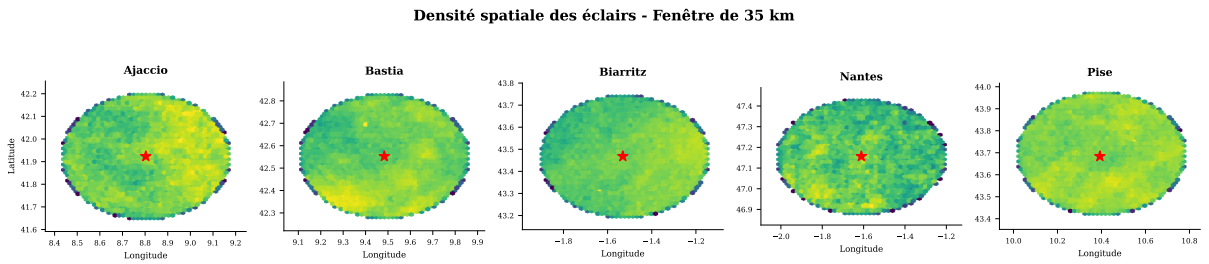

Figure 7 – Densité spatiale des éclairs dans un rayon d'environ 35 km autour de chaque aéroport. L'étoile rouge indique la position de l'aéroport. On note des clusters intenses liés au relief (Corse, Apennins).

Les cartes révèlent des structures spatiales propres à chaque site : Ajaccio et Bastia montrent des éclairs concentrés sur les reliefs intérieurs corses ; Pise présente une dispersion vers les Apennins à l'est ; Biarritz et Nantes ont des distributions plus homogènes, typiques des environnements de plaine atlantique.

6 Analyse des sessions d'alerte

6.1 Durée et intensité des sessions

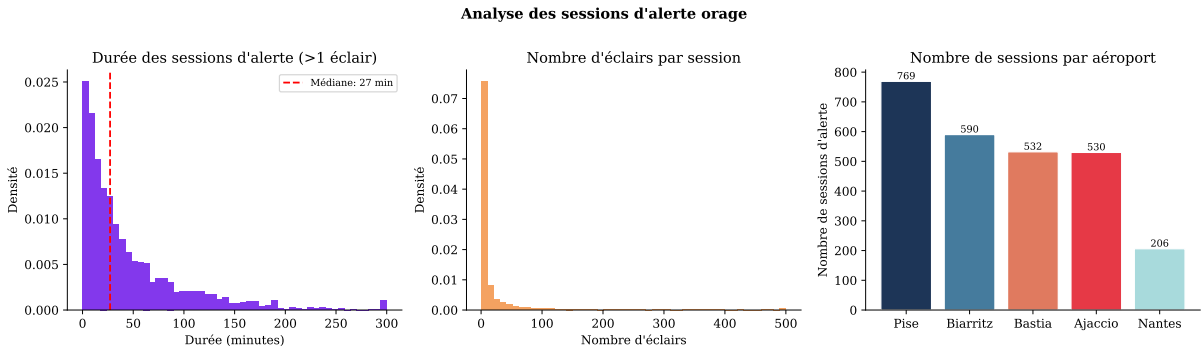

Figure 8 – Caractéristiques des 769 sessions d'alerte. Le nombre d'éclairs par session suit une forte loi asymétrique, avec de très nombreuses sessions mineures, mais aussi des sessions majeures atteignant un millier d'éclairs.

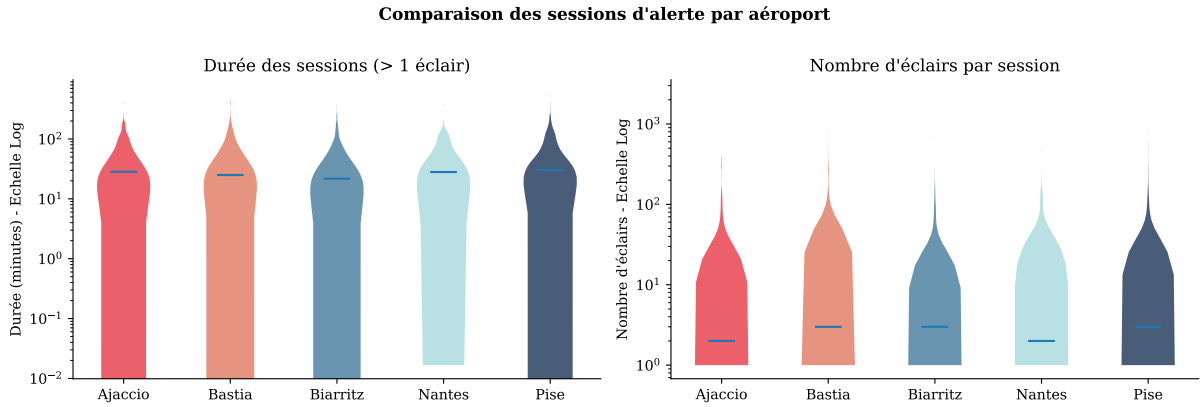

Figure 9 – Comparaison des sessions par aéroport. Pise présente les sessions les plus longues et les plus intenses (médiane élevée en nombre d'éclairs). Biarritz et Nantes ont des sessions plus courtes mais potentiellement plus imprévisibles.

6.2 Spécificités par aéroport

Profils orageaux par aéroport

- **Pise** : L'aéroport le plus actif en volume absolu, avec un pic de fin d'été.
- **Ajaccio & Bastia** : Saisonnalité quasi-identique (août à octobre).
- **Nantes** : Orages plus rares mais concentrés en début d'été (mai-juillet), marqués par un flux SW puissant.
- **Biarritz** : Fort ratio de décharges IC et vents orageux d'est (effet pyrénéen et transition océan/continent).

7 Analyse de la variable cible

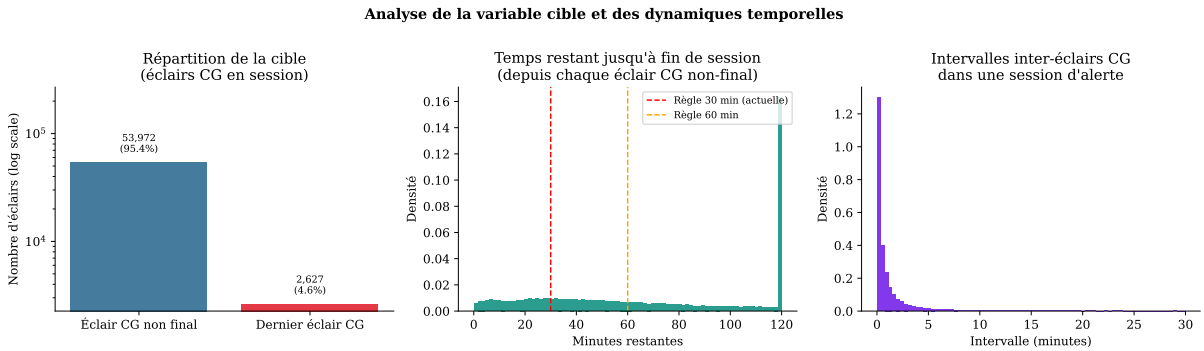

Figure 10 – **Gauche** : la cible est fortement déséquilibrée — le dernier éclair CG ne représente qu'une fraction des éclairs en session (par définition, un par session). **Centre** : distribution du temps restant jusqu'à la fin de session — la règle fixe d'attente de 30 minutes après un éclair ne capture que 25.0% du temps restant total de la tempête ; une prédiction dynamique peut réduire significativement ce décalage. **Droite** : intervalles inter-éclairs CG, avec une queue lourde significative.

7.1 Formulation du problème de modélisation

Deux formulations complémentaires sont envisagées pour la Phase 2 :

1. **Classification binaire** : pour chaque éclair CG en session, prédire $P(\text{dernier éclair CG}) \in [0, 1]$. Le modèle produit une probabilité de fin d'orage en temps réel.
2. **Régression de survie** : modéliser le temps restant T jusqu'au dernier éclair CG comme une variable de survie censurée, avec :

$$P(T > t \mid \mathcal{F}_t) = S(t \mid \mathcal{F}_t)$$

où $\mathcal{F}_t$ est l'historique des éclairs jusqu'au temps t.

7.2 Exemple de session d'alerte

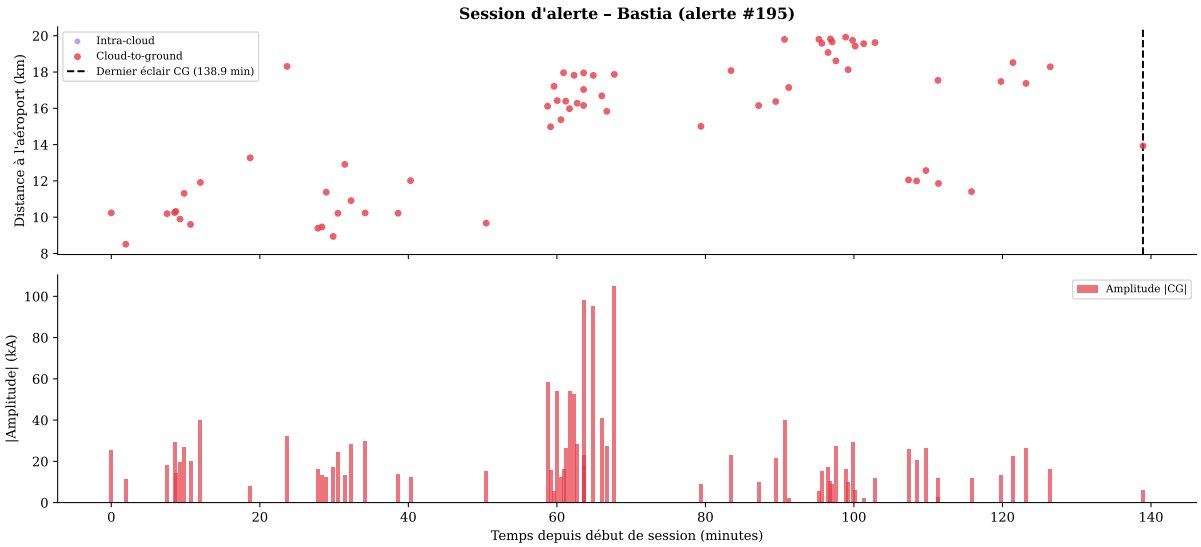

Figure 11 – Exemple d'une session d'alerte complète. Le panneau supérieur montre la distance à l'aéroport des éclairs IC (violet) et CG (rouge) au cours du temps. Le panneau inférieur montre l'évolution de l'amplitude des éclairs CG. La ligne pointillée noire indique le moment du dernier éclair CG — c'est ce que le modèle doit apprendre à anticiper.

8 Corrélations et structure des données

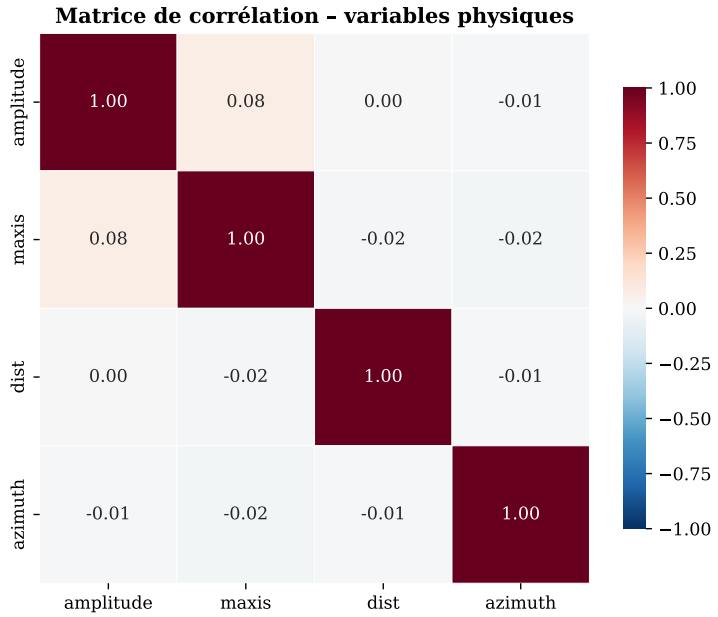

Figure 12 – Matrice de corrélation de Pearson des variables physiques. Contrairement à l'attente initiale, l'amplitude et `maxis` présentent une corrélation quasi-inexistante (0.08). Cela signifie qu'elles mesurent des caractéristiques très distinctes de la décharge (puissance vs profil). La distance et l'azimuth sont également quasi-indépendants des variables physiques.

9 Conclusions et orientations pour la modélisation

Points clés de l'analyse

- **Forte saisonnalité** : les modèles devront être entraînés/évalués en respectant la structure temporelle (pas de leakage temporel dans la validation).
- **Hétérogénéité inter-aéroports** : un encodage de l'aéroport ou des modèles spécifiques par site seront nécessaires.
- **Déséquilibre de classes** : la cible est déséquilibrée par construction (1 dernier éclair par session). Des techniques de pondération ou d'échantillonnage seront requises.
- **Structure séquentielle** : l'ordre temporel des éclairs dans une session est l'information la plus riche. Les modèles devront intégrer cette dimension (features de fenêtre glissante, processus ponctuels, RNN/Transformer...).
- **Signal de dissipation** : le ratio IC croissant en fin de session et l'augmentation des intervalles inter-éclairs CG sont des signaux prometteurs.

9.1 Features candidates pour la modélisation

Feature	Description
`time_since_alert_start`	Temps écoulé depuis le début de la session (min)
`time_since_last_cg`	Intervalle depuis le dernier éclair CG (min)
`n_cg_last_10min`	Nombre d'éclairs CG dans les 10 dernières minutes
`n_ic_last_10min`	Nombre d'éclairs IC dans les 10 dernières minutes
`icloud_ratio_recent`	Ratio IC/(IC+CG) sur fenêtre glissante
`mean_dist_recent`	Distance moyenne des éclairs récents
`dist_centroid_drift`	Déplacement du centroïde des éclairs récents
`amplitude_trend`	Tendance (pente) de l'amplitude sur les derniers CG
`maxis_trend`	Tendance de maxis
`airport`	Encodage de l'aéroport
`hour_utc`	Heure UTC (signal diurne)
`month`	Mois (signal saisonnier)

Table 2 – Features candidates pour les modèles de Phase 2

A Environnement technique

- Langage : Python 3.14, environnement `pew orage`
- Librairies : `pandas 3.0`, `numpy`, `matplotlib`, `seaborn`, `scikit-learn`, `scipy`
- Compilation : MiKTeX 26.2 (pdfLaTeX)