Prédiction de fin d'orage

Phase 2 — Fiches d'évaluation des modèles

Réponse à l'appel d'offre **Météorage**

Comparaison de 5 approches de modélisation
pour l'estimation du temps résiduel d'orage

Mars 2026

5 modèles · 56 599 éclairs · 2 627 sessions d'alerte

Table des matières

1 Vue d'ensemble et comparaison **2**

2 Modèle 1 — Baseline (règle fixe 30 minutes) **3**
2.1 Fonctionnement . . . 3
2.2 Résultats . . . 3
2.3 Pistes d'amélioration . . . 3

3 Modèle 2 — XGBoost Survival (AFT) **4**
3.1 Fonctionnement . . . 4
3.2 Résultats . . . 4
3.3 Analyse . . . 4
3.4 Pistes d'amélioration . . . 5

4 Modèle 3 — Processus de Hawkes (Classique) **6**
4.1 Fonctionnement . . . 6
4.2 Résultats . . . 6
4.3 Analyse . . . 6
4.4 Pistes d'amélioration . . . 7

5 Modèle 4 — Neural Hawkes Process (GRU) **8**
5.1 Fonctionnement . . . 8
5.2 Résultats . . . 8
5.3 Analyse . . . 8
5.4 Pistes d'amélioration . . . 8

6 Modèle 5 — Bayesian Neural Network (MC Dropout) **9**
6.1 Fonctionnement . . . 9
6.2 Résultats . . . 9
6.3 Analyse . . . 9
6.4 Pistes d'amélioration . . . 9

7 Synthèse et recommandation **11**

1 Vue d'ensemble et comparaison

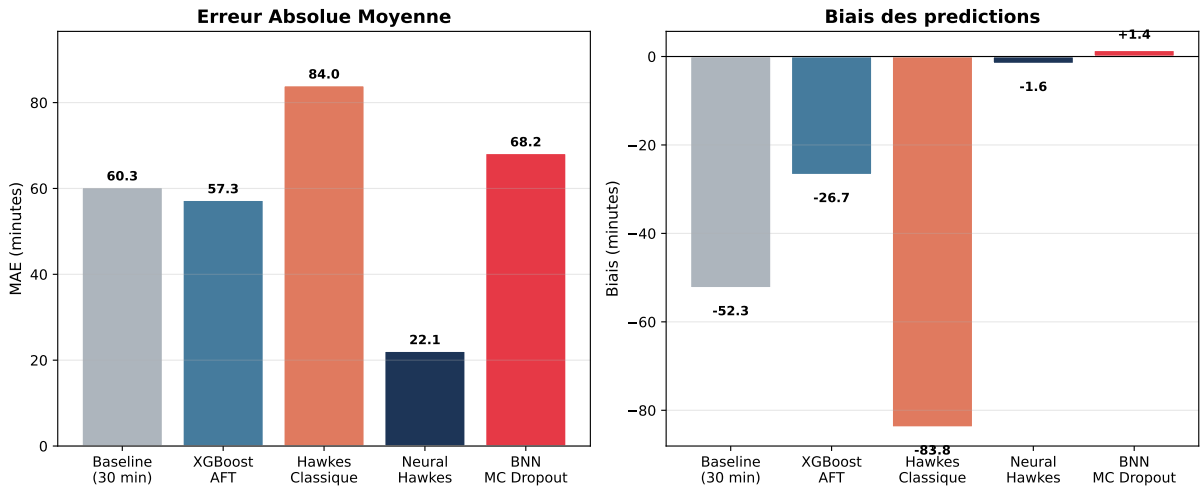

Figure 1 – Comparaison globale des 5 modèles : erreur absolue moyenne (gauche) et biais de prédiction (droite). Le Neural Hawkes domine nettement avec une MAE de 22 min et un biais quasi nul.

Modèle	MAE	RMSE	Médiane	P90	Biais
Baseline (30 min)	60.26	94.05	33.32	132.48	−52.32
XGBoost AFT	57.28	90.69	33.18	149.82	−26.74
Hawkes Classique	83.99	124.37	56.88	178.96	−83.82
Neural Hawkes (GRU)	**22.11**	**32.50**	**18.00**	**40.12**	**−1.61**
BNN MC Dropout	68.20	102.98	34.31	164.40	+1.42

Table 1 – Métriques comparatives sur le jeu de validation (14 770 éclairs, 526 sessions). Toutes les valeurs sont en minutes.

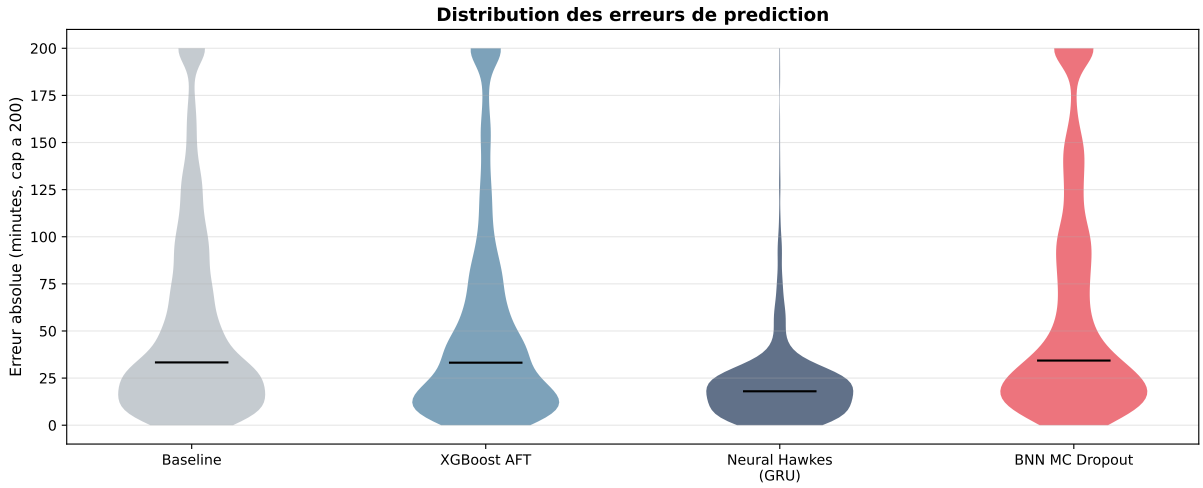

Figure 2 – Distribution des erreurs absolues pour les 4 modèles principaux. Le Neural Hawkes (GRU) présente une distribution nettement plus resserrée vers zéro que les trois autres.

2 Modèle 1 — Baseline (règle fixe 30 minutes)

2.1 Fonctionnement

La règle métier actuelle consiste à maintenir l'alerte pendant une durée fixe de 30 minutes après la détection du dernier éclair cloud-to-ground (CG). Le "temps restant" prédit est donc constant : $\hat{T} = 30$ min, indépendamment du contexte.

2.2 Résultats

Métriques Baseline

- MAE = 60.26 min — erreur moyenne élevée
- Biais = −52.32 min — sous-estimation chronique du temps restant
- Médiane = 33.32 min — la moitié des prédictions sont erronées de plus de 33 min

Le biais fortement négatif (−52 min) signifie que la règle sous-estime systématiquement le temps restant. Pour les sessions longues (plusieurs heures), prédire 30 min est catastrophiquement optimiste. À l'inverse, pour les sessions très courtes, la règle surestime et maintient l'alerte inutilement.

2.3 Pistes d'amélioration

Aucune — c'est la référence. Son rôle est de quantifier le gain apporté par les modèles.

3 Modèle 2 — XGBoost Survival (AFT)

3.1 Fonctionnement

XGBoost est un algorithme d'ensemble par gradient boosting sur des arbres de décision. La variante `survival:aft` (*Accelerated Failure Time*) modélise directement $\ln(T)$ comme une variable de régression, où T est le temps avant la fin de l'orage.

Features utilisées (20 au total) :

- Temporelles : temps depuis le début, temps depuis le dernier CG
- Fenêtres glissantes (15/30 min) : comptage d'éclairs, ratio IC/CG
- Spatiales : distance moyenne, tendance de distance (approche/recul)
- Physiques : amplitude, maxis
- Cycliques : encodage sin/cos de l'heure et du mois

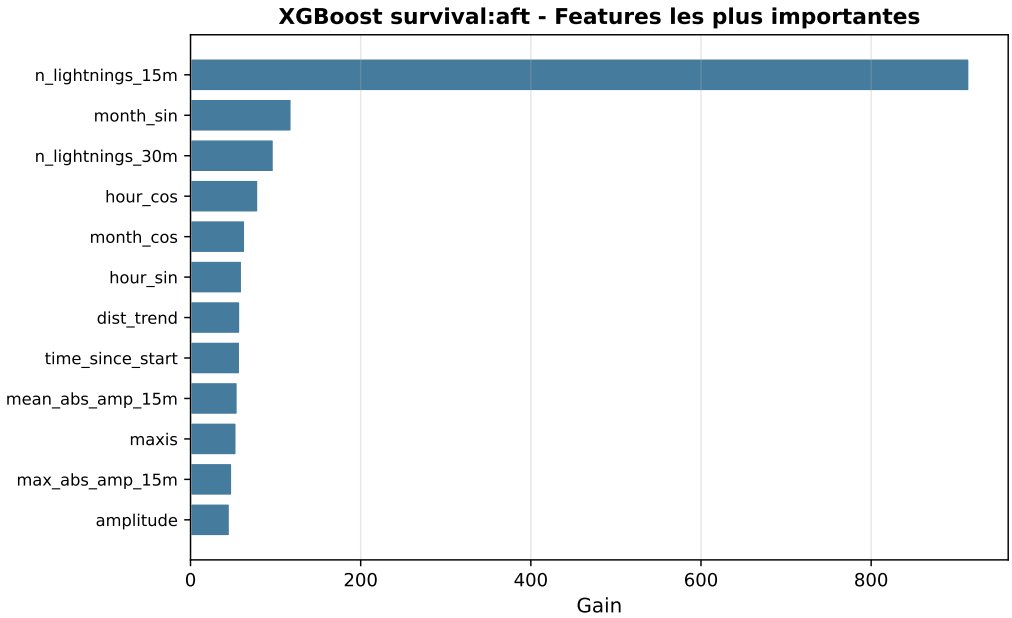

Figure 3 – Importance des features (gain) pour XGBoost AFT. Le nombre d'éclairs dans les 15 dernières minutes (`n_lightnings_15m`) domine très largement, indiquant que la densité temporelle récente est le signal le plus informatif.

3.2 Résultats

Métriques XGBoost AFT

- MAE = 57.28 min — légère amélioration vs baseline
- Biais = −26.74 min — réduit de moitié vs baseline
- La feature `n_lightnings_15m` domine (gain = 915)
- Early stopping à 108 boosting rounds (sur 500 max)

3.3 Analyse

L'amélioration modeste s'explique par le fait que XGBoost traite chaque éclair **indépendamment**. Il ne capture pas la dynamique séquentielle : l'ordre et l'espacement des éclairs ne sont exploités qu'indirectement via les features de fenêtre glissante.

3.4 Pistes d'amélioration

— Ajouter des features séquentielles plus riches (tendances sur 5/10/20 min)
— Encoder la géographie (lat/lon relative, azimuth récent)
— Tester `survival:cox` (risques proportionnels) comme alternative
— Utiliser un split temporel strict (par date) plutôt que par session

4 Modèle 3 — Processus de Hawkes (Classique)

4.1 Fonctionnement

Le processus de Hawkes est un processus ponctuel **autoexcitant** : chaque événement (éclair) augmente momentanément la probabilité d'observer un prochain événement. L'intensité conditionnelle s'écrit :

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha \cdot \beta \cdot e^{-\beta(t-t_i)}$$

- μ = taux de fond (intensité de base)
- α = magnitude de l'excitation
- β = taux de décroissance de l'excitation

La fin de l'orage est prédite quand $\lambda(t)$ tombe en dessous d'un seuil fixé.

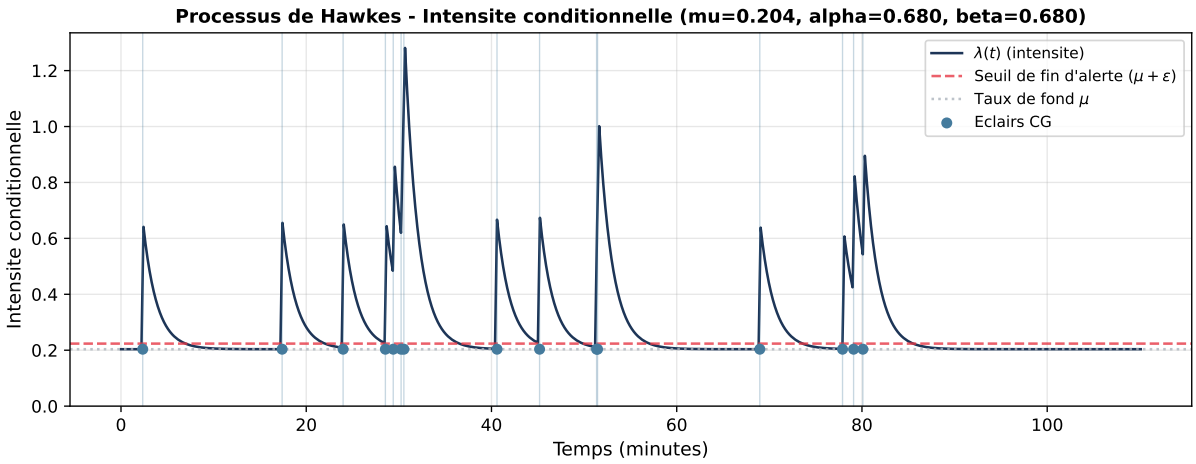

Figure 4 – Exemple d'intensité conditionnelle du processus de Hawkes. Chaque éclair CG (barres bleues) provoque un pic d'excitation qui décroît exponentiellement. Quand l'intensité passe sous le seuil rouge, l'alerte est levée.

4.2 Résultats

Paramètres et Métriques Hawkes Classique

- Paramètres ajustés : $\mu = 0.204$, $\alpha = 0.680$, $\beta = 0.680$
- MAE = 83.99 min — le plus mauvais modèle, y compris derrière la baseline
- Biais = −83.82 min — sous-estime drastiquement le temps restant (coupure prématurée)
- Le *branching ratio* $\alpha = 0.68 < 1$ confirme la stationnarité du processus (chaque événement engendre en moyenne 0.68 descendant, soit un processus sous-critique)

4.3 Analyse

La performance décevante, marquée par une sous-estimation systématique (−83 min), s'explique par la **simplicité du noyau exponentiel**. L'excitation retombe très vite sous le seuil de tolérance (ici réglé à $\mu + \varepsilon$), menant le modèle à déclarer la fin de l'orage bien trop tôt entre deux rafales lointaines. De plus, le modèle univarié ignore l'amplitude et la géométrie de la convection, ne lui laissant aucune indication si le front approche ou s'éloigne.

4.4 Pistes d'amélioration

— Noyau multivarié : distinguer les éclairs IC et CG
— Noyau somme d'exponentielles pour capturer plusieurs échelles temporelles
— Marques spatio-temporelles : pondérer l'excitation par la distance et l'amplitude
— Seuil adaptatif par aéroport

5 Modèle 4 — Neural Hawkes Process (GRU)

5.1 Fonctionnement

Le Neural Hawkes Process remplace le noyau exponentiel paramétrique par un **réseau de neurones récurrent** (GRU). L'idée :

1. Chaque éclair est représenté par un vecteur de features (icloud, amplitude, distance, maxis).
2. Un GRU accumule l'historique des événements dans un état caché h_t.
3. L'intensité est calculée par : $\lambda(t) = \text{softplus}(W_h \cdot h_{t_{\text{last}}} + w_\Delta \cdot \Delta t + b)$

Contrairement au Hawkes classique, ce modèle :

— Apprend des **interactions non-linéaires** entre les features
— Capture des **dépendances à long terme** dans la séquence
— S'adapte aux **caractéristiques physiques** de chaque éclair

5.2 Résultats

Métriques Neural Hawkes (GRU) — Meilleur modèle

— **MAE = 22.11 min** — 3× meilleur que la baseline
— **RMSE = 32.50 min** — erreurs extrêmes fortement réduites
— **Médiane = 18.00 min** — la moitié des prédictions à moins de 18 min d'erreur
— **Biais = −1.61 min** — prédictions quasi non biaisées
— **P90 = 40.12 min** — 90% des erreurs sous 40 min

5.3 Analyse

Ce modèle combine le meilleur des deux mondes :

— La **formulation en processus ponctuel** du Hawkes, naturelle pour un flux d'éclairs
— La **puissance d'apprentissage** d'un réseau récurrent (GRU)

Il chute nettement les erreurs pour les sessions longues (où les modèles à features fixes échouent) car il peut "mémoriser" la dynamique entière de la séquence.

5.4 Pistes d'amélioration

— Remplacer le GRU par un **Transformer** pour capturer les dépendances globales
— Ajouter des features spatiales (azimuth, centroïde mobile)
— Entraîner un modèle par aéroport pour capturer les spécificités locales
— Intégrer un mécanisme d'attention temporelle (Temporal Attention)
— Augmenter la taille du dataset avec des données synthétiques

6 Modèle 5 — Bayesian Neural Network (MC Dropout)

6.1 Fonctionnement

Le BNN utilise l'approximation **Monte Carlo Dropout** : un MLP classique (128-64-32 neurones) dont les couches Dropout restent actives pendant l'inférence. En effectuant $N = 100$ passages forward, on obtient une **distribution de prédictions** :

- La **moyenne** des N passages donne la prédiction $\hat{T}$
- L'**écart-type** donne l'incertitude σ

L'intérêt opérationnel est majeur : un contrôleur aérien peut voir non seulement "l'orage finira dans 45 min" mais aussi "± 20 min d'incertitude".

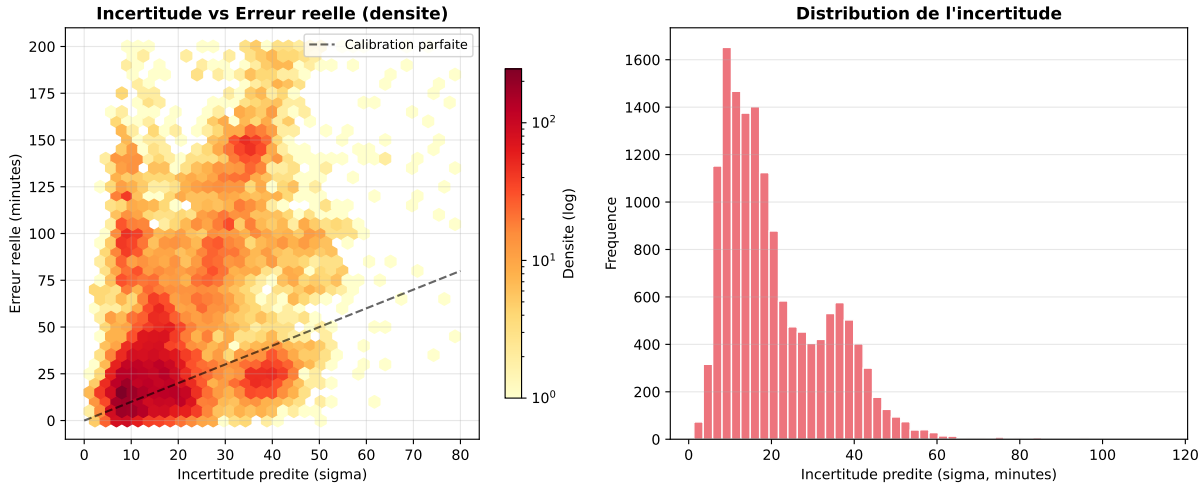

Figure 5 – **Gauche** : incertitude prédite vs erreur réelle. Idéalement, les points devraient suivre la diagonale. **Droite** : distribution de l'incertitude prédite, centrée autour de 20 minutes.

6.2 Résultats

Métriques BNN MC Dropout

- MAE = 68.20 min — performance proche de la baseline en termes d'erreur
- Biais = +1.42 min — quasi nul (prédictions non biaisées)
- Incertitude moyenne = 20.98 min
- Calibration : 25.1% dans 1σ (idéal 68.3%) — sous-calibré

6.3 Analyse

Le BNN avec MC Dropout donne des prédictions **non biaisées** mais avec une erreur élevée. La calibration est insuffisante (25% dans 1σ au lieu de 68%), ce qui signifie que le modèle **sous-estime son incertitude**. Cela vient du fait que le MC Dropout est une approximation grossière de l'inférence bayésienne véritable, et que le réseau est trop petit et ne traite pas la séquence.

6.4 Pistes d'amélioration

- Utiliser une inférence bayésienne complète (Pyro, TFP) au lieu du MC Dropout
- Combiner avec le Neural Hawkes : GRU bayésien pour avoir séquentialité + incertitude

— Ajouter une perte de calibration (ex : CRPS, calibration loss)
— Augmenter la taille du réseau et le nombre d'epochs
— Tester le Concrete Dropout (dropout rate appris)

7 Synthèse et recommandation

Classement final

1. **Neural Hawkes (GRU)** — Le meilleur sur toutes les métriques (MAE = 22.11, biais ≈ 0). Sa formulation en processus ponctuel est naturelle pour les séquences d'éclairs.
2. **XGBoost AFT** — Meilleur modèle tabulaire (MAE = 57.28), limité par l'absence de modélisation séquentielle. Facile à déployer en production.
3. **Baseline (30 min)** — Référence métier (MAE = 60.26). Dépassée en MAE par XGBoost et Neural Hawkes, mais reste devant le BNN et le Hawkes classique.
4. **BNN MC Dropout** — MAE plus élevée que la baseline (68.20 vs 60.26), mais apporte une information complémentaire unique : l'incertitude. Son biais quasi nul (+1.42) et sa capacité à quantifier la confiance en font un candidat intéressant *en complément* d'un modèle plus précis.
5. **Hawkes Classique** — Le noyau exponentiel univarié est trop faible (MAE = 83.99), mais le cadre théorique est validé par le succès spectaculaire du Neural Hawkes.

La recommandation est de retenir le **Neural Hawkes Process** comme modèle principal, éventuellement enrichi de composantes bayésiennes pour produire des intervalles de confiance opérationnels. Un XGBoost AFT pourrait servir de modèle de repli simple pour les environnements à faibles ressources de calcul.