Prédiction de fin d'orage

Data Battle IA PAU 2026 — Météorage

Colin Geindre Alexandre Hayoun Tao Levray

Mars 2026

Équipe : **Les Vieux Briscards**

Plan

Phase 1 — Exploration des données

Phase 2 — Comparaison de modèles

Phase 3 — Spécialisation et améliorations

Conclusion et démonstration

Phase 1 — Exploration des données

Contexte et problématique

Problème métier :

- Les alertes orage sont maintenues **30 min** après le dernier éclair CG
- Approche conservatrice ⇒ pertes d'exploitation aéroportuaires

Objectif :

- Estimer en **temps réel** le temps résiduel avant la fin de l'orage
- Réduire les faux maintiens d'alerte tout en garantissant la sécurité

Dataset

Éclairs	507 071
Aéroports	5
Sessions	769
Éclairs / alerte	56 599

5 sites : Ajaccio, Bastia, Biarritz, Nantes, Pise

Répartition par aéroport

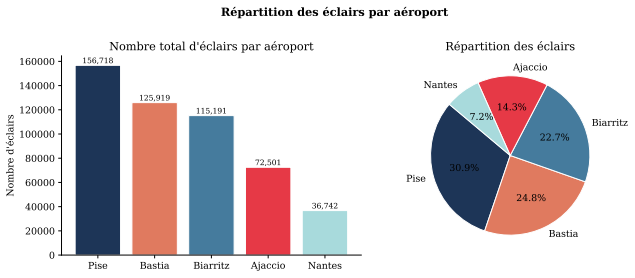

- **Pise** domine ($> 30\%$)
- Bastia $\approx 2\times$ Ajaccio malgré la proximité géographique
- Nantes : activité la plus faible

Patterns temporels

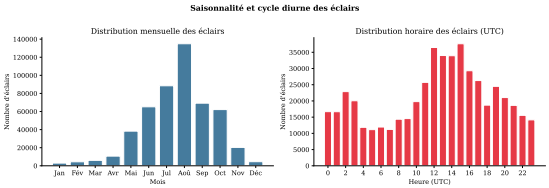

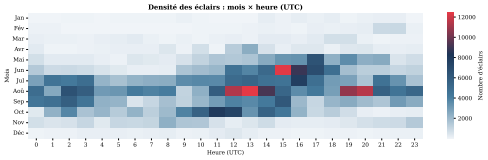

Saisonnalité estivale marquée (pic juin–sept.) · **Cycle diurne** avec maximum 12h–15h UTC

Profil saisonnier par aéroport

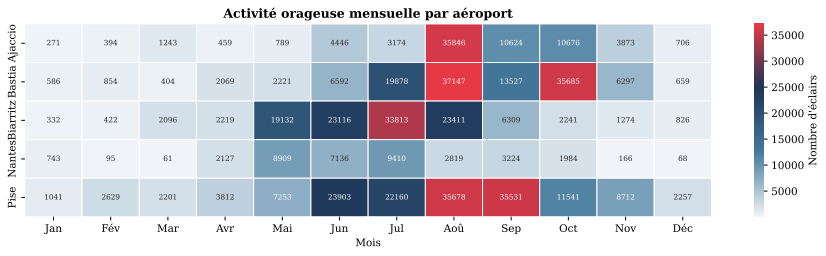

Biarritz : pic **précoce** (mai–août) · Pise : pic **tardif** (août–sept.) · Corse : pic **automnal** (août–oct.)

Direction des orages (rose des azimuts)

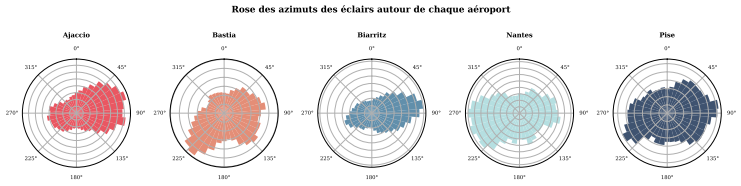

Chaque aéroport a un **profil directionnel unique** $\Rightarrow$ pertinence d'une composante spatiale

Répartition géographique des éclairs

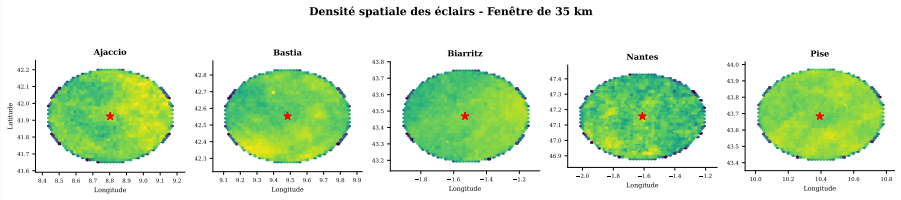

Clusters liés au relief (Corse, Apennins) — distributions homogènes en plaine (Nantes)

Synthèse de l'EDA

Enseignements clés

- Forte **saisonnalité** et **cycle diurne** $\Rightarrow$ features temporelles cycliques
- **Hétérogénéité** entre aéroports $\Rightarrow$ encodage du site
- **Déséquilibre de classes** par construction $\Rightarrow$ formulation régression/survie
- **Structure séquentielle** = information la plus riche $\Rightarrow$ processus ponctuels, RNN
- Signaux de **dissipation** : ratio IC $\nearrow$, intervalles inter-CG $\nearrow$

Phase 2 — Comparaison de modèles

Résultats globaux

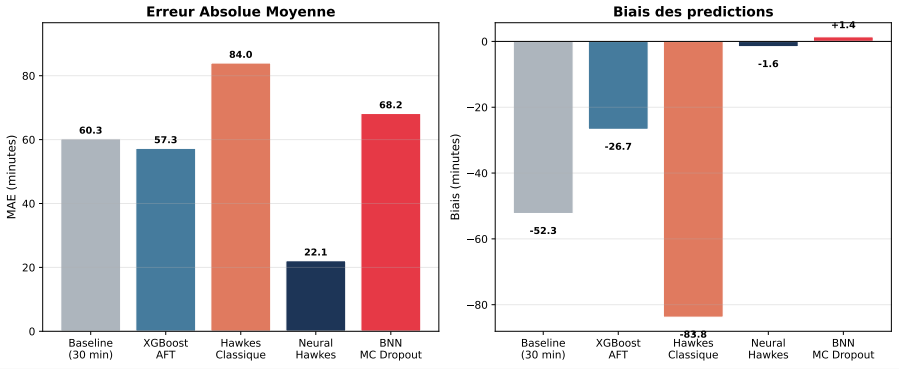

Modèle	MAE	RMSE	Méd.	Biais	P90
Baseline 30 min	60.26	94.05	33.32	−52.32	132.48
XGBoost AFT	57.28	90.69	33.18	−26.74	149.82
Hawkes Classique	83.99	124.37	56.88	−83.82	178.96
Neural Hawkes (GRU)	**22.11**	**32.50**	**18.00**	**−1.61**	**40.12**

XGBoost AFT — modèle tabulaire

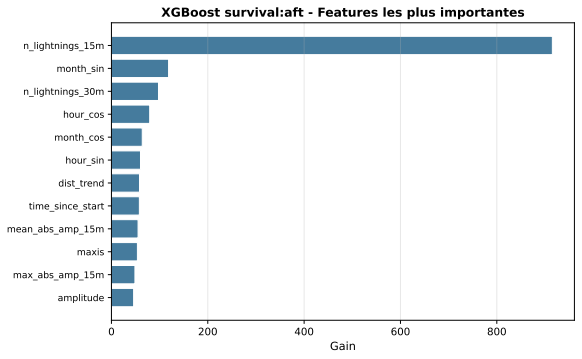

- Modélise $\ln(T)$ via Accelerated Failure Time
- 20 features (temporelles, spatiales, physiques)
- MAE = 57.28 min ($\sim$ baseline)
- **Limite** : traite chaque éclair *indépendamment*
- `n_lightnings_15m` domine

Processus de Hawkes classique

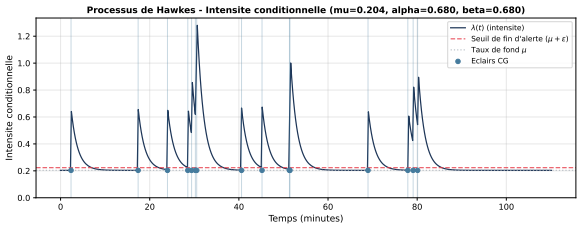

Intensité conditionnelle :

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha\beta\, e^{-\beta(t-t_i)}$$

- MAE = 83.99 min (**pire** modèle)
- Noyau exponentiel trop simpliste
- **Mais** : le cadre théorique est validé par le Neural Hawkes

Neural Hawkes Process (GRU) — meilleur modèle

Principe :
Remplacer le noyau exponentiel par un **GRU** qui apprend la dynamique :

$$\lambda(t) = \text{softplus}\big(W_h \cdot h_t + w_\Delta \cdot \Delta t + b\big)$$

Avantages :

- Interactions **non-linéaires** entre features
- Dépendances **à long terme**
- Capture la physique de chaque éclair

Métriques	
MAE	**22.11 min**
RMSE	32.50 min
Médiane	18.00 min
Biais	−1.61 min
P90	40.12 min

3× meilleur que la baseline
Biais **quasi nul**

Distribution des erreurs

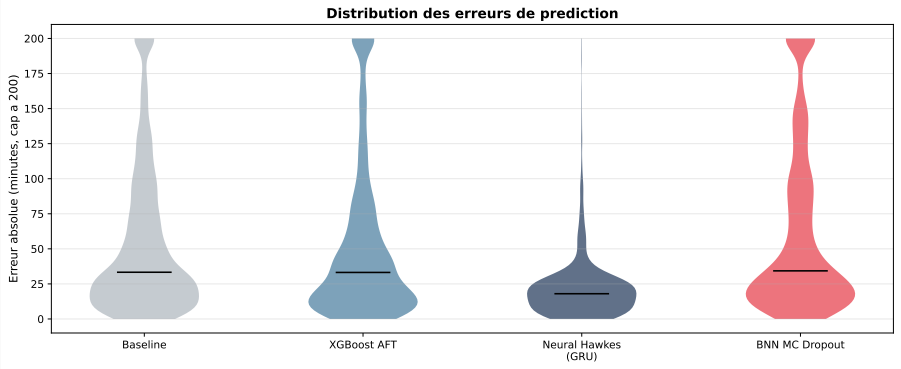

Le Neural Hawkes (GRU) a une distribution **nettement plus resserrée** vers zéro

Synthèse Phase 2

Classement final

1. **Neural Hawkes (GRU)** — MAE = 22.11, biais ≈ 0 ✓
2. **XGBoost AFT** — MAE = 57.28, bon modèle tabulaire
3. **Baseline** — MAE = 60.26, référence métier
4. **BNN MC Dropout** — Incertitude utile mais MAE élevée
5. **Hawkes classique** — Trop simpliste mais cadre validé

$\Rightarrow$ Le **Neural Hawkes Process** est retenu comme base pour la phase suivante

Phase 3 — Spécialisation et améliorations

Axes d'amélioration

1. **Enrichissement des features** : 4 $\rightarrow$ 12 features (azimuth, densité, tendance distance, ratio IC...)
2. **Architecture Transformer** avec encodage positionnel continu
3. **Sortie Gaussienne en log-space** : résout le biais de la régression Huber
4. **Estimation d'incertitude** (MC Dropout, variationnel)
5. **Modèles spécialisés** par aéroport
6. **Spatial Mixture of Experts (MoE)** : $N = 3$ experts guidés par la cinématique

Enrichissement des features

#	Feature	Description
0–3	icloud, amplitude, dist, maxis	Phase 2 (inchangées)
4–5	azimuth_sin, azimuth_cos	Direction encodée cycliquement
6	dt_since_last	Temps inter-événement
7	dt_since_last_cg	Temps depuis le dernier CG
8	density_5min	Nb éclairs / 5 min
9	ic_ratio_recent	Ratio IC récent (10 derniers)
10	dist_to_centroid	Distance au centroïde mobile
11	dist_trend	Tendance distance (+ = éloignement)

Motivation : capturer les signaux de **dissipation** (éloignement, baisse de densité, ratio IC $\nearrow$)

Sortie Gaussienne en espace log — la clé

Problème : la distribution du temps restant est très asymétrique $\Rightarrow$ la Huber loss biaise vers les grandes valeurs.

Solution : $z = \log(1 + y)$ normalise la distribution.

$$\mathcal{L}_{\text{Gauss}} = \frac{1}{2}\left[\frac{(z-\mu)^2}{\sigma^2} + 2\log\sigma\right]$$

La prédiction finale : $\hat{y} = e^{\mu} - 1$
L'incertitude est **naturellement calibrée**.

Impact (la plus grande amélioration)

	Avant	Après
Biais	+11.04	**+1.96**
MAE	26.59	**21.33**
Médiane	24.18	**15.96**

Biais : -82%
MAE : -20%
Médiane : -34%

Résultats comparatifs — toutes variantes

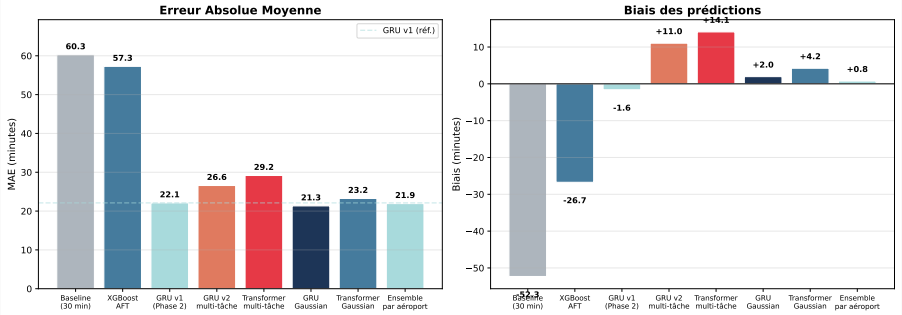

It.	Variante	MAE	RMSE	Méd.	Biais	P90
Réf.	Baseline 30 min	60.26	—	—	−52.32	—
Réf.	GRU v1 (Phase 2)	22.11	32.50	18.00	−1.61	40.12
v3	**GRU Gaussian (log)**	**21.33**	**30.25**	**15.96**	**+1.96**	**42.13**
v3	Transformer Gaussian	23.25	31.59	19.34	+4.23	43.12

Performance par aéroport

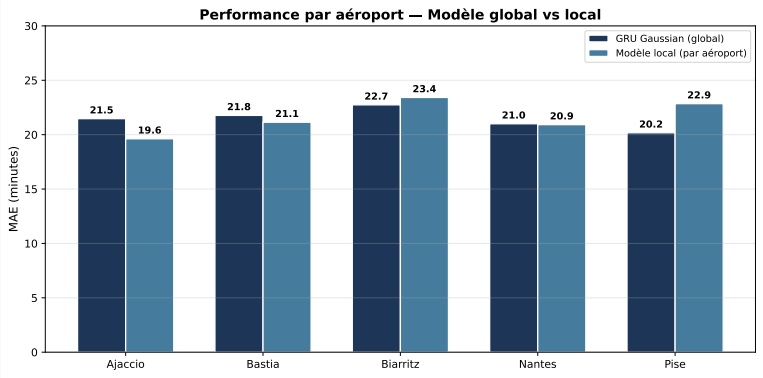

Homogénéité entre aéroports : écart max de **2.57 min** sur la MAE.

La spécialisation par aéroport n'améliore que marginalement (Δ MAE $\approx +0.60$ min)

Conclusion et démonstration

Résultats finaux

Modèle final — GRU Gaussian (log)

MAE	**21.33 min** (vs 60.26 baseline)
RMSE	30.25 min
Médiane	15.96 min
Biais	+1.96 min
Calibration	96.4% dans 2σ

Progression

Baseline	60.26 min
XGBoost AFT	57.28 min
Neural Hawkes v1	22.11 min
GRU Gaussian	**21.33 min**

Réduction de −65% par rapport à la baseline

+ **Interface web interactive** pour explorer les sessions orageuses et les prédictions

`https://mstrdav.github.io/prediction-orage/interactive/`

Perspectives

1. **Plus de données** : le dataset (1 682 sessions) reste limité
2. **Features météo** : données radar (réflectivité, vent)
3. **Recalibration** isotonique pour corriger la sur-couverture
4. **Hybride MoE + GRU** : combiner la puissance séquentielle du GRU avec la spécialisation spatiale du MoE
5. **Déploiement temps réel** : intégration dans les systèmes d'alerte existants

Merci pour votre attention !

Questions ?

Les Vieux Briscards
Colin Geindre · Alexandre Hayoun · Tao Levray

https://github.com/Mstrdav/prediction-orage
https://mstrdav.github.io/prediction-orage/interactive/